数据中心网络——实验手册3：eBPF Packet教程

基于eBPF的防火墙

本文将介绍如何使用eBPF进行网络数据包的解析和处理。我们将实现一个简单的防火墙，屏蔽来自特定IP地址的数据包。

一、实验环境

- VMware Workstation Pro
- Ubuntu 22.04

本次实验的相关依赖*应当*与Ubuntu版本无关，但仅保证Ubuntu 22.04可以正常执行，如果遇到问题可以联系助教。

二、准备工作

1. 安装相关依赖

   在终端执行以下命令：

   ```
   sudo apt install clang llvm libelf-dev libbpf-dev libpcap-dev gcc-multilib
   build-essential linux-tools-$(uname -r)
   ```

三、实验介绍

1. 实验简述

   上上周我们利用内核模块实现了一个简单的防火墙，本次实验中，我们会利用eBPF来实现相同的目标，包括：

   - 基于eBPF/TC，屏蔽由223.5.5.5发送的数据包
   - 基于eBPF/XDP，屏蔽由223.5.5.5发送的数据包

2. 实验思路

   与内核模块的实验类似，eBPF下的思路如下：

   1. 分析与网络数据相关的xdp_md或__sk_buff结构体
   2. 判断相应结构体数据是否满足需求，并返回对应的响应参数

四、开始实验

1. 解析器函数parser
   在内核模块中，我们使用了内核提供的`ip_hdr()`函数来对sk_buff结构体进行解析，同时取出IP报文的头部。
   但在eBPF中，由于eBPF虚拟机的存在以及内核安全性的要求等，我们没有办法直接调用`ip_hdr()`函数来提取IP头部，如果强行使用，可以正常编译，但在尝试加载时会报错：

```
zhaidoudou123@Lab-virtual-machine:~/eBPF/packet/tc$ sudo tc filter add dev ens33 egress bpf direct-action obj tc.o sec tc
libbpf: failed to find BTF for extern 'ip_hdr': -3
ERROR: opening BPF object file failed
Unable to load program
```

   幸运的是，XDP项目在其教程xdp-tutorial中提供了一个现成的parser库`parsing_helper.c`，我们可以直接调用。
   我们以IP头部的解析器`parse_iphdr`为例来简要介绍：

```c
/* Header cursor to keep track of current parsing position */
struct hdr_cursor {
    void *pos;
};


static __always_inline int parse_iphdr(struct hdr_cursor *nh,
                   void *data_end,
                   struct iphdr **iphdr)
{
    struct iphdr *iph = nh->pos;
    int hdrsize;

    if (iph + 1 > data_end)
        return -1;

    hdrsize = iph->ihl * 4;
    /* Sanity check packet field is valid */
    if(hdrsize < sizeof(*iph))
        return -1;

    /* Variable-length IPv4 header, need to use byte-based arithmetic */
    if (nh->pos + hdrsize > data_end)
        return -1;

    nh->pos += hdrsize;
    *iphdr = iph;

    return iph->protocol;
}
```

   该函数的输入为三个指针，`nh`为一个结构体`hdr_cursor`的指针，该结构体中的`pos`对象用于追踪在`xdp_md`或`__sk_buff`结构体中当前解析的位置，`data_end`是指向`xdp_md`或`__sk_buff`结构体的尾部的指针，`iphdr`指针指向解析后的IP头部。
   具体步骤如下：

   1. 首先，检查`nh->pos`是否指向一个有效的IP报文头部，如果不是，返回`-1`。
      这里利用了C语言的一个语法糖，结构体+1代表指针向后移动一整个结构体。如果此时的指针位置

大于data_end则意味着中间不存在IP头部，返回-1。

2. 然后，计算IP报文头部的大小，因为它可能有可选字段。大小等于iph->ihl乘以四，其中iph->ihl表示报文头部的长度（以32位为单位）。
   接着，检查nh->pos加上报文头部的大小是否超过了data_end，如果是，则意味着不存在有效的IP头部，返回-1。
3. 最后，将nh->pos向后移动报文头部的大小，将iph赋值给*iphdr，返回iph->protocol表示IP报文的协议字段。

下一节中我们将介绍对应的eBPF程序如何调用这个解析函数。

2. 核心代码编写
本节主要以TC为例，并在注释中给出XDP的实现。

```
/* A eBPF/TC firewall to block packets from 223.5.5.5 */
int droppacket(struct __sk_buff *skb){ // XDP: int droppacket(struct xdp_md
*ctx){

    void *data_end = (void *)(long)skb->data_end;
    void *data = (void *)(long)skb->data;
    /* For XDP, just replace skb with ctx */
    struct hdr_cursor nh;
    struct ethhdr *eth;
    int eth_type;
    int ip_type;
    struct iphdr *iphdr;


    /* These keep track of the next header type and iterator pointer */
    nh.pos = data;
    /* Parse Ethernet */
    eth_type = parse_ethhdr(&nh, data_end, &eth);
    if (eth_type != bpf_htons(ETH_P_IP))
    return TC_ACT_OK; // XDP: return XDP_PASS;

    /* Parse IP headers */
    ip_type = parse_iphdr(&nh, data_end, &iphdr);
    if (ip_type == -1)
    return TC_ACT_OK;

    if(iphdr->saddr == 0x050505DF){ // 223.5.5.5's hex, Big-endian mode.
        // drop the packet
        return TC_ACT_SHOT; // XDP: return XDP_DROP;
        }
    return TC_ACT_OK;
}
```

在该代码中，我们通过nh结构体中的pos对象跟踪网络数据处理位置，并依次调用以太网帧、IP报文的解析器，并根据结果返回响应。如果某个包从223.5.5.5发来，就丢弃它，反之让其通过。 完整代码见本文末尾。

3. 编译与加载
   在编写代码完成后，我们需要将其编译成为可以加载至系统内核的eBPF对象文件，并在终端中执行相关命令进行加载。

   1. 编译
      在终端中执行如下命令进行编译：

      ```
      clang -O2 -target bpf -c tc.c -o tc.o
      ```

   2. TC程序的加载与卸载
      加载：

      ```
      # 网卡接口需要自行通过ip a命令查看
      sudo tc qdisc add dev ens33 clsact
      sudo tc filter add dev ens33 ingress bpf direct-action obj tc.o sec tc
      ```

      卸载：

      ```
      sudo tc qdisc del dev ens33 clsact
      ```

   3. XDP程序的加载与卸载
      加载：

      ```
      # 网卡接口需要自行通过ip a命令查看
      sudo ip link set dev ens33 xdp obj xdp.o sec xdp
      ```

      卸载：

      ```
      sudo ip link set dev ens33 xdp off
      ```

五、实验结果

两个实验的结果是一致的，在此只展示eBPF/TC的结果：

六、参考资料及建议

- XDP-tutorial
  https://github.com/xdp-project/xdp-tutorial

七、新尝试

之前的内核模块课上的额外实验中，我们对ICMP协议以及本机发出的目标为223.5.5.5数据包进行了屏蔽，在eBPF下我们同样也可以做到这件事，只需要修改`iph->saddr`为`iph->daddr`即可。需要注意的是，对于流出方向的数据包，只有eBPF/TC可以进行相关的操作，XDP做不到。

而本周的新尝试是，实现一个针对特定端口的防火墙。
例如，ssh服务的端口号是`22`，且使用TCP协议。我们的目标是屏蔽一切目标端口为`22`的TCP报文。

提示

1. 协议的判断可以通过判断`iph->protocol`是否为`IPPROTO_TCP`实现，记得首先`#include <linux/in.h>`。
2. 先利用`parse_tcphdr()`函数解析TCP头部后再进行端口判断，该函数定义在`parsing_helpers.h`头文件中，返回值为`int`类型，值为TCP头部中储存的TCP头部长度。
3. 端口由`tcphdr`结构体的`dest`或`source`对象决定，本次只需要针对流入流量处理即可，所以选择`dest`对象，即指向本机的目标端口。具体用法为`tcphdr->dest`。另外，端口号为大段顺序的16位整数，`22`对应的大段十六进制端口号为`0x1600`。
4. 使用XDP或TC均可。

八、代码附录

1. `tc.c`

```c
/* SPDX-License-Identifier: GPL-2.0 */
#include <linux/bpf.h>
#include <linux/pkt_cls.h>
#include "bpf/bpf_helpers.h"
#include "bpf/bpf_endian.h"
#include "parsing_helpers.h"


SEC("tc")
int droppacket(struct __sk_buff *skb){
    void *data_end = (void *)(long)skb->data_end;
    void *data = (void *)(long)skb->data;
    struct hdr_cursor nh;
    struct ethhdr *eth;
    int eth_type;
    int ip_type;
    struct iphdr *iphdr;


    /* These keep track of the next header type and iterator pointer */
    nh.pos = data;
    /* Parse Ethernet */
```

```
    eth_type = parse_ethhdr(&nh, data_end, &eth);
    if (eth_type != bpf_htons(ETH_P_IP)) return TC_ACT_OK;

    /* Parse IP/IPv6 headers */
    ip_type = parse_iphdr(&nh, data_end, &iphdr);
    if (ip_type == -1) return TC_ACT_OK;

    if (iphdr->saddr == 0x050505DF){ // 223.5.5.5's hex, Big-endian mode.
        // drop the packet
        return TC_ACT_SHOT;
        }
    return TC_ACT_OK;
}
char _license[] SEC("license") = "GPL";
```

2. xdp.c

```
/* SPDX-License-Identifier: GPL-2.0 */
#include <linux/bpf.h>
#include "bpf/bpf_helpers.h"
#include "bpf/bpf_endian.h"
#include "parsing_helpers.h"


SEC("xdp")
int droppacket(struct xdp_md *ctx){
    void *data_end = (void *)(long)ctx->data_end;
    void *data = (void *)(long)ctx->data;
    struct hdr_cursor nh;
    struct ethhdr *eth;
    int eth_type;
    int ip_type;
    struct iphdr *iphdr;


    /* These keep track of the next header type and iterator pointer */
    nh.pos = data;
    /* Parse Ethernet */
    eth_type = parse_ethhdr(&nh, data_end, &eth);
    if (eth_type != bpf_htons(ETH_P_IP)) return XDP_PASS;

    /* Parse IP/IPv6 headers */
    ip_type = parse_iphdr(&nh, data_end, &iphdr);
    if (ip_type == -1) return XDP_PASS;

    if (iphdr->saddr == 0x050505DF){ // 223.5.5.5's hex, Big-endian mode.
        // drop the packet
        return XDP_DROP;
    }
    return XDP_PASS;
}
char _license[] SEC("license") = "GPL";
```

3. parsing_helpers.h
   需要放在与tc.c、xdp.c相同的目录下
   该文件包括了以太网、IPv4/v6、TCP/UDP、ICMP、VLAN tag以及VXLAN等协议的解析器

```
/* SPDX-License-Identifier: (GPL-2.0-or-later OR BSD-2-clause) */
/*
* This file contains parsing functions that are used in the packetXX XDP
* programs. The functions are marked as __always_inline, and fully defined
in
* this header file to be included in the BPF program.
*
* Each helper parses a packet header, including doing bounds checking, and
* returns the type of its contents if successful, and -1 otherwise.
*
* For Ethernet and IP headers, the content type is the type of the payload
* (h_proto for Ethernet, nexthdr for IPv6), for ICMP it is the ICMP type
field.
* All return values are in host byte order.
*
* The versions of the functions included here are slightly expanded versions
of
* the functions in the packet01 lesson. For instance, the Ethernet header
* parsing has support for parsing VLAN tags.
*/

#ifndef __PARSING_HELPERS_H
#define __PARSING_HELPERS_H

#include <stddef.h>
#include <linux/if_ether.h>
#include <linux/if_packet.h>
#include <linux/ip.h>
#include <linux/ipv6.h>
#include <linux/icmp.h>
#include <linux/icmpv6.h>
#include <linux/udp.h>
#include <linux/tcp.h>

/* Header cursor to keep track of current parsing position */
struct hdr_cursor {
    void *pos;
};

/*
*   struct vlan_hdr - vlan header
*   @h_vlan_TCI: priority and VLAN ID
*   @h_vlan_encapsulated_proto: packet type ID or len
*/
struct vlan_hdr {
    __be16  h_vlan_TCI;
```

```
    __be16  h_vlan_encapsulated_proto;
};

/* VXLAN protocol (RFC 7348) header:
* +-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+
* |R|R|R|R|I|R|R|R|               Reserved                        |
* +-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+
* |                VXLAN Network Identifier (VNI) |   Reserved    |
* +-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+-+
*
* I = VXLAN Network Identifier (VNI) present.
*/
struct vxlanhdr {
    __be32 vx_flags;
    __be32 vx_vni;
};

/*
* Struct icmphdr_common represents the common part of the icmphdr and
icmp6hdr
* structures.
*/
struct icmphdr_common {
    __u8        type;
    __u8        code;
    __sum16 cksum;
};

/* Allow users of header file to redefine VLAN max depth */
#ifndef VLAN_MAX_DEPTH
#define VLAN_MAX_DEPTH 2
#endif

#define VLAN_VID_MASK       0x0fff /* VLAN Identifier */
/* Struct for collecting VLANs after parsing via parse_ethhdr_vlan */
struct collect_vlans {
    __u16 id[VLAN_MAX_DEPTH];
};

static __always_inline int proto_is_vlan(__u16 h_proto)
{
    return !!(h_proto == bpf_htons(ETH_P_8021Q) ||
        h_proto == bpf_htons(ETH_P_8021AD));
}

/* Notice, parse_ethhdr() will skip VLAN tags, by advancing nh->pos and
returns
* next header EtherType, BUT the ethhdr pointer supplied still points to the
* Ethernet header. Thus, caller can look at eth->h_proto to see if this was
a
* VLAN tagged packet.
*/
static __always_inline int parse_ethhdr_vlan(struct hdr_cursor *nh,
                         void *data_end,
```

```
                        struct ethhdr **ethhdr,
                        struct collect_vlans *vlans)
{
    struct ethhdr *eth = nh->pos;
    int hdrsize = sizeof(*eth);
    struct vlan_hdr *vlh;
    __u16 h_proto;
    int i;

    /* Byte-count bounds check; check if current pointer + size of header
    * is after data_end.
    */
    if (nh->pos + hdrsize > data_end)
        return -1;

    nh->pos += hdrsize;
    *ethhdr = eth;
    vlh = nh->pos;
    h_proto = eth->h_proto;

    /* Use loop unrolling to avoid the verifier restriction on loops;
    * support up to VLAN_MAX_DEPTH layers of VLAN encapsulation.
    */
    #pragma unroll
    for (i = 0; i < VLAN_MAX_DEPTH; i++) {
        if (!proto_is_vlan(h_proto))
            break;

        if (vlh + 1 > data_end)
            break;

        h_proto = vlh->h_vlan_encapsulated_proto;
        if (vlans) /* collect VLAN ids */
            vlans->id[i] =
                (bpf_ntohs(vlh->h_vlan_TCI) & VLAN_VID_MASK);

        vlh++;
    }

    nh->pos = vlh;
    return h_proto; /* network-byte-order */
}

static __always_inline int parse_ethhdr(struct hdr_cursor *nh,
                    void *data_end,
                    struct ethhdr **ethhdr)
{
    /* Expect compiler removes the code that collects VLAN ids */
    return parse_ethhdr_vlan(nh, data_end, ethhdr, NULL);
}

static __always_inline int parse_ip6hdr(struct hdr_cursor *nh,
                    void *data_end,
                    struct ipv6hdr **ip6hdr)
```

```
{
    struct ipv6hdr *ip6h = nh->pos;

    /* Pointer-arithmetic bounds check; pointer +1 points to after end of
    * thing being pointed to. We will be using this style in the remainder
    * of the tutorial.
    */
    if (ip6h + 1 > data_end)
        return -1;

    nh->pos = ip6h + 1;
    *ip6hdr = ip6h;

    return ip6h->nexthdr;
}

static __always_inline int parse_iphdr(struct hdr_cursor *nh,
                   void *data_end,
                   struct iphdr **iphdr)
{
    struct iphdr *iph = nh->pos;
    int hdrsize;

    if (iph + 1 > data_end)
        return -1;

    hdrsize = iph->ihl * 4;
    /* Sanity check packet field is valid */
    if(hdrsize < sizeof(*iph))
        return -1;

    /* Variable-length IPv4 header, need to use byte-based arithmetic */
    if (nh->pos + hdrsize > data_end)
        return -1;

    nh->pos += hdrsize;
    *iphdr = iph;

    return iph->protocol;
}

static __always_inline int parse_icmp6hdr(struct hdr_cursor *nh,
                   void *data_end,
                   struct icmp6hdr **icmp6hdr)
{
    struct icmp6hdr *icmp6h = nh->pos;

    if (icmp6h + 1 > data_end)
        return -1;

    nh->pos   = icmp6h + 1;
    *icmp6hdr = icmp6h;

    return icmp6h->icmp6_type;
```

```
}

static __always_inline int parse_icmphdr(struct hdr_cursor *nh,
                    void *data_end,
                    struct icmphdr **icmphdr)
{
    struct icmphdr *icmph = nh->pos;

    if (icmph + 1 > data_end)
        return -1;

    nh->pos  = icmph + 1;
    *icmphdr = icmph;

    return icmph->type;
}

static __always_inline int parse_icmphdr_common(struct hdr_cursor *nh,
                        void *data_end,
                        struct icmphdr_common **icmphdr)
{
    struct icmphdr_common *h = nh->pos;

    if (h + 1 > data_end)
        return -1;

    nh->pos  = h + 1;
    *icmphdr = h;

    return h->type;
}

/*
* parse_vxlanhdr: parse the vxlan header and return the VNI of the udp
payload
*/
static __always_inline int parse_vxlanhdr(struct hdr_cursor *nh,
                    void *data_end,
                    struct vxlanhdr **vxlanhdr)
{
    // int len;
    struct vxlanhdr *h = nh->pos;

    if (h + 1 > data_end)
        return -1;

    nh->pos  = h + 1;
    *vxlanhdr = h;
    // if ((h->vx_flags &
(0b00000000000000000000000000010000))!=0b00000000000000000000000000010000)
    //  return -1;

    return h->vx_vni;
}
```

```c
/*
* parse_udphdr: parse the udp header and return the length of the udp
payload
*/
static __always_inline int parse_udphdr(struct hdr_cursor *nh,
                    void *data_end,
                    struct udphdr **udphdr)
{
    int len;
    struct udphdr *h = nh->pos;

    if (h + 1 > data_end)
        return -1;

    nh->pos  = h + 1;
    *udphdr = h;

    len = bpf_ntohs(h->len) - sizeof(struct udphdr);
    if (len < 0)
        return -1;

    return len;
}


/*
* parse_tcphdr: parse and return the length of the tcp header
*/
static __always_inline int parse_tcphdr(struct hdr_cursor *nh,
                    void *data_end,
                    struct tcphdr **tcphdr)
{
    int len;
    struct tcphdr *h = nh->pos;

    if (h + 1 > data_end)
        return -1;

    len = h->doff * 4;
    /* Sanity check packet field is valid */
    if(len < sizeof(*h))
        return -1;

    /* Variable-length TCP header, need to use byte-based arithmetic */
    if (nh->pos + len > data_end)
        return -1;

    nh->pos += len;
    *tcphdr = h;

    return len;
}
```

```
#endif /* __PARSING_HELPERS_H */
```